

Задача 1

а) Будем использовать следующие условия регулярности:

1. Для любой статистики $k(x)$ с конечным вторым моментом выполнено:

$$\frac{\partial}{\partial \theta} \mathbb{E}_\theta k(x) = \mathbb{E}_\theta \left(k(x) \frac{\partial}{\partial \theta} \ln f_\theta(x) \right)$$

2. Функция правдоподобия (и логарифм от неё) везде дифференцируема по θ .

Доказательство:

Пусть $f(y | \theta)$ - функция вероятности. Рассмотрим $D_{KL}[f(y | \theta) || f(y | \phi)]$.

$$\begin{aligned} D_{KL}[f(y | \theta) || f(y | \phi)] &= \mathbb{E}_\theta [\ln f(y | \theta) - \ln f(y | \phi)] \\ &= \sum_{y \in Y} f(y | \theta) \ln f(y | \theta) - \sum_{y \in Y} f(y | \theta) \ln f(y | \phi) \end{aligned} \quad (1)$$

Разложим в ряд Тейлора функцию вероятности (используя то, что рассматривается $\phi \rightarrow \theta$):

$$\ln f(y | \phi) = \ln f(y | \theta) + (\phi - \theta) \frac{\partial}{\partial \theta} \ln f(y | \theta) + (\phi - \theta)^2 \frac{\partial^2}{2\partial \theta^2} \ln f(y | \theta) + O((\phi - \theta)^3) \quad (2)$$

Подставим ряд (2) в (1):

$$\begin{aligned} D_{KL}[f(y | \theta) || f(y | \phi)] &= \sum_{y \in Y} f(y | \theta) \ln f(y | \theta) - \sum_{y \in Y} f(y | \theta) \left(\ln f(y | \theta) \right. \\ &\quad \left. + (\phi - \theta) \frac{\partial}{\partial \theta} \ln f(y | \theta) + (\phi - \theta)^2 \frac{\partial^2}{2\partial \theta^2} \ln f(y | \theta) + O((\phi - \theta)^3) \right) \\ &= \underbrace{\sum_{y \in Y} f(y | \theta) \ln f(y | \theta) - \sum_{y \in Y} f(y | \theta) \ln f(y | \theta)}_{=0} \\ &\quad - \underbrace{(\phi - \theta) \sum_{y \in Y} f(y | \theta) \frac{\partial}{\partial \theta} \ln f(y | \theta)}_{[3]} \\ &\quad - \underbrace{\frac{(\phi - \theta)^2}{2} \sum_{y \in Y} f(y | \theta) \frac{\partial^2}{\partial \theta^2} \ln f(y | \theta) + O((\phi - \theta)^3)}_{[4]} \end{aligned}$$

Преобразуем (3) и (4), используя условия регулярности:

$$\begin{aligned} \sum_{y \in Y} f(y | \theta) \frac{\partial}{\partial \theta} \ln f(y | \theta) &= \sum_{y \in Y} \frac{f(y | \theta)}{f(y | \theta)} \frac{\partial}{\partial \theta} f(y | \theta) \\ &= \sum_{y \in Y} \frac{\partial}{\partial \theta} f(y | \theta) \stackrel{\text{рег-ть}}{=} \frac{\partial}{\partial \theta} \sum_{y \in Y} f(y | \theta) = 0 \end{aligned} \quad (3)$$

$$\begin{aligned} \sum_{y \in Y} f(y | \theta) \frac{\partial^2}{\partial \theta^2} \ln f(y | \theta) &= \sum_{y \in Y} f(y | \theta) \frac{\partial}{\partial \theta} \left(\frac{1}{f(y | \theta)} \frac{\partial}{\partial \theta} f(y | \theta) \right) \\ &= \sum_{y \in Y} f(y | \theta) \left(- \left(\frac{1}{f(y | \theta)} \frac{\partial}{\partial \theta} f(y | \theta) \right)^2 + \frac{1}{f(y | \theta)} \frac{\partial^2}{\partial \theta^2} f(y | \theta) \right) \\ &= \sum_{y \in Y} \frac{\partial^2}{\partial \theta^2} f(y | \theta) - \sum_{y \in Y} f(y | \theta) \left(\frac{1}{f(y | \theta)} \frac{\partial}{\partial \theta} f(y | \theta) \right)^2 \\ &\stackrel{\text{рег-ть}}{=} \underbrace{\frac{\partial^2}{\partial \theta^2} \sum_{y \in Y} f(y | \theta)}_{=0} - \underbrace{\sum_{y \in Y} f(y | \theta) \left(\frac{\partial}{\partial \theta} \ln f(y | \theta) \right)^2}_{= \mathbb{E}_\theta \left(\frac{\partial}{\partial \theta} \ln f(y | \theta) \right)^2 \stackrel{\text{def}}{=} I(\theta)} \\ &= -I(\theta) \end{aligned} \quad (4)$$

Вернёмся к исходному выражению и подставим результаты (3) и (4):

$$D_{KL}[f(y | \theta) || f(y | \phi)] = 0 - 0 - \frac{(\phi - \theta)^2}{2} (-I(\theta)) + O((\phi - \theta)^3) = \frac{(\phi - \theta)^2 I(\theta)}{2} + O((\phi - \theta)^3)$$

Used source: [Stackexchange: Connection between Fisher metric and the relative entropy](#)

- b) Покажем, что при большей информации Фишера ML-оценки лежат ближе к истинному параметру:

Рассмотрим две модели с истинными значениями θ_a и θ_b и их оценками θ_a^* , θ_b^* соответственно, такие что дивергенции у них одинаковы, а информация Фишера первой модели больше другой:

$$\frac{1}{2} I(\theta_a) \Delta \theta_a^2 + O(\Delta \theta_a^3) = \frac{1}{2} I(\theta_b) \Delta \theta_b^2 + O(\Delta \theta_b^3) \iff \frac{1}{2} (I(\theta_a) \Delta \theta_a^2 - I(\theta_b) \Delta \theta_b^2) = O(\Delta \theta_b^3 - \Delta \theta_a^3)$$

Допустим, $\Delta\theta_a > \Delta\theta_b$. Но тогда получаем, что правая часть больше нуля, а левая меньше, что противоречит равенству.

Таким образом, получаем, что при большей информации Фишера ($I(\theta_a) > I(\theta_b)$) расстояние между оценкой и истинным значением меньше ($\Delta\theta_a < \Delta\theta_b$).

Задача 2

а) Рассмотрим функцию правдоподобия:

$$f(X_1, X_2, \dots, X_n | q) = \left(\frac{2}{q}\right)^n \cdot X_1 \cdot X_2 \cdot \dots \cdot X_n \cdot e^{-\frac{\sum_{i=1}^n X_i^2}{q}} I\{X_1, \dots, X_n > 0\}$$

$$\ell(X, q) = \ln f = n \ln \frac{2}{q} + \sum_{i=1}^n \ln X_i - \frac{1}{q} \sum_{i=1}^n X_i^2, \quad X_i > 0$$

Найдём \hat{q}_{ML} :

$$\begin{aligned} \ell'_q &= -\frac{n}{q} + \frac{\sum_{i=1}^n X_i^2}{q^2} \\ -\frac{n}{\hat{q}} + \frac{\sum_{i=1}^n X_i^2}{\hat{q}^2} &= 0 \iff \frac{n}{\hat{q}} = \frac{\sum_{i=1}^n X_i^2}{\hat{q}^2} \iff \hat{q}_{ML} = \overline{X^2} \end{aligned}$$

Проверим, является ли найденное значение точкой максимума:

$$\ell''_{qq} = \frac{n}{q^2} - 2 \frac{\sum_{i=1}^n X_i^2}{q^3} \quad \ell''_{qq}(\hat{q}) = -\frac{n}{(\overline{X^2})^2} < 0 \implies \hat{q} - \text{точка максимума}$$

б) Поскольку функция $g(x) = x^2$ - гладкая, можем использовать следующее утверждение из семинара: $\widehat{g(q)} = g(\hat{q})$. Отсюда:

$$\widehat{q^2}_{ML} = \hat{q}^2_{ML} = (\overline{X^2})^2$$

с) Найдём информацию Фишера по определению $I(q) = \mathbb{E}(-\ell''_{qq})$:

$$\ell''_{qq} = \frac{n}{q^2} - \frac{2}{q^3} \sum_{i=1}^n X_i^2$$

$$\mathbb{E}(-\ell''_{qq}) = \mathbb{E}\left(-\frac{n}{q^2} + \frac{2}{q^3} \sum_{i=1}^n X_i^2\right) = \frac{2}{q^3} \mathbb{E} \sum_{i=1}^n X_i^2 - \frac{n}{q^2}$$

Найдём $\mathbb{E}X_i^2$:

$$\mathbb{E}X_i^2 = \int_{\mathbb{R}} f(x | q) x^2 dx = \int_0^{+\infty} \frac{2x}{q} e^{-\frac{x^2}{q}} x^2 dx = \left[\frac{x^2/q=t}{2x dx/q=dt} \right] = \int_0^{+\infty} qte^{-t} dt = q \cdot \Gamma(2) = q$$

Вернёмся к информации Фишера:

$$I(q) = \mathbb{E}(-\ell''_{qq}) = \frac{2}{q^3} \cdot nq - \frac{n}{q^2} = \frac{n}{q^2}$$

Из этого получим дисперсию:

$$\text{Var}(\hat{q}) = I^{-1}(\hat{q}) = \frac{\hat{q}^2}{n} = \frac{(\overline{X^2})^2}{n}$$

Получаем 95%-ый доверительный интервал для q :

$$\left[\overline{X^2} - 1.96 \cdot \frac{\overline{X^2}}{\sqrt{n}}; \overline{X^2} + 1.96 \cdot \frac{\overline{X^2}}{\sqrt{n}} \right]$$

Ответ: а) $\hat{q} = \overline{X^2}$; б) $\hat{q}^2 = (\overline{X^2})^2$; в) $\left[\overline{X^2} - 1.96 \cdot \frac{\overline{X^2}}{\sqrt{n}}; \overline{X^2} + 1.96 \cdot \frac{\overline{X^2}}{\sqrt{n}} \right]$

Задача 3

$$\begin{cases} y_1 = 75 - \text{кол-во палочек из вишни} \\ y_2 = 30 - \text{кол-во палочек из дуба} \\ y_3 = 45 - \text{кол-во палочек из вяза} \end{cases}, n = 150$$

а) Рассмотрим функцию правдоподобия:

$$f(y, p) = p_1^{y_1} p_2^{y_2} (1 - p_1 - p_2)^{y_3} \binom{n}{y_1, y_2, y_3}$$

$$f(y, p) = p_1^{75} p_2^{30} (1 - p_1 - p_2)^{45} \binom{150}{75, 30, 45}$$

$$\ell(y, p) = \ln f = 75 \ln p_1 + 30 \ln p_2 + 45 \ln(1 - p_1 - p_2) + C$$

Найдём p_{ML} :

$$\begin{cases} \ell'_{p_1} = \frac{75}{p_1} - \frac{45}{1-p_1-p_2} \\ \ell'_{p_2} = \frac{30}{p_2} - \frac{45}{1-p_1-p_2} \end{cases} \longrightarrow \begin{cases} \frac{75}{\hat{p}_1} - \frac{45}{1-\hat{p}_1-\hat{p}_2} = 0 \\ \frac{30}{\hat{p}_2} - \frac{45}{1-\hat{p}_1-\hat{p}_2} = 0 \end{cases} \iff \begin{cases} \hat{p}_1 = 0.5 \\ \hat{p}_2 = 0.2 \end{cases}$$

$$\hat{p}_{ML} = \begin{pmatrix} 0.5 \\ 0.2 \end{pmatrix}$$

Проверим, являются ли найденные значения точкой максимума:

$$\ell''_{p_1 p_1} = -\frac{y_1}{p_1^2} - \frac{y_3}{p_3^2} \quad \ell''_{p_2 p_2} = -\frac{y_2}{p_2^2} - \frac{y_3}{p_3^2} \quad \ell''_{p_1 p_2} = -\frac{y_3}{p_3^2}$$

$$H(\hat{p}) = \begin{pmatrix} -800 & -500 \\ -500 & -700 \end{pmatrix} - \text{отрицательно определена} \implies \hat{p} - \text{точка максимума}$$

b) 1. Проверим гипотезу по LR тесту: $LR = 2(\max \ell_{UR} - \max \ell_R)$

Найдём максимум функции ℓ при H_0 :

$$\ell_R(y, p) = 75 \ln 0.7 + 30 \ln p_2 + 45 \ln(1 - 0.7 - p_2) + C$$

$$\ell'_{R p_2} = \frac{30}{p_2} - \frac{45}{0.3 - p_2} \longrightarrow \frac{30}{\hat{p}_{2R}} - \frac{45}{0.3 - \hat{p}_{2R}} = 0 \iff \hat{p}_{2R} = 0.12$$

Проверим, являются ли найденные значения точкой максимума, рассмотрев матрицу Гессе (вторые производные посчитаны в предыдущем пункте):

$$H(\hat{p}_R) = \begin{pmatrix} -\frac{680000}{9} & -\frac{12500}{9} \\ -\frac{12500}{9} & -\frac{31250}{9} \end{pmatrix} - \text{отрицательно определена} \implies \hat{p} - \text{точка максимума}$$

Подставим найденные оценки (для ℓ_{UR} оценка \hat{p}_{ML} найдена в предыдущем пункте):

$$LR = 2((75 \ln 0.5 + 30 \ln 0.2 + 45 \ln 0.3) - (75 \ln 0.7 + 30 \ln 0.12 + 45 \ln 0.18)) = 26.153$$

$$\chi_{\text{crit}} = 3.84 < 26.153 \implies \text{гипотеза опровергается}$$

2. Проверим гипотезу по LM тесту: $LM = \hat{s}_R^T (\widehat{\text{Var}}(\hat{s}_R))^{-1} \hat{s}_R$

Из предыдущего пункта имеем оценки параметров при ограничении:

$$\hat{p}_R = \begin{pmatrix} 0.7 \\ 0.12 \end{pmatrix}$$

Найдём информацию Фишера:

$$\ell''_{p_1 p_1} = -\frac{y_1}{p_1^2} - \frac{y_3}{p_3^2} \quad \ell''_{p_2 p_2} = -\frac{y_2}{p_2^2} - \frac{y_3}{p_3^2} \quad \ell''_{p_1 p_2} = -\frac{y_3}{p_3^2}$$

$$I(p) = \mathbb{E}(-H) = \mathbb{E} \begin{pmatrix} \frac{y_1}{p_1^2} + \frac{y_3}{p_3^2} & \frac{y_3}{p_3^2} \\ \frac{y_3}{p_3^2} & \frac{y_2}{p_2^2} + \frac{y_3}{p_3^2} \end{pmatrix} = \begin{pmatrix} \frac{np_1}{p_1^2} + \frac{np_3}{p_3^2} & \frac{np_3}{p_3^2} \\ \frac{np_3}{p_3^2} & \frac{np_2}{p_2^2} + \frac{np_3}{p_3^2} \end{pmatrix} = n \begin{pmatrix} \frac{1}{p_1} + \frac{1}{p_3} & \frac{1}{p_3} \\ \frac{1}{p_3} & \frac{1}{p_2} + \frac{1}{p_3} \end{pmatrix}$$

Найдём оценку информации Фишера:

$$I_R = 150 \begin{pmatrix} \frac{1}{0.7} + \frac{1}{0.18} & \frac{1}{0.18} \\ \frac{1}{0.18} & \frac{1}{0.12} + \frac{1}{0.18} \end{pmatrix} = 1500 \begin{pmatrix} \frac{44}{63} & \frac{5}{9} \\ \frac{9}{25} & \frac{18}{18} \end{pmatrix}$$

$$\widehat{\text{Var}}(\hat{s}_R)^{-1} = I_R^{-1} = \frac{1}{1500} \cdot \frac{3}{250} \begin{pmatrix} 175 & -70 \\ -70 & 88 \end{pmatrix}$$

Подставим оценки в score function:

$$\hat{s}_R = \begin{pmatrix} \frac{75}{0.7} - \frac{45}{0.18} \\ \frac{30}{0.12} - \frac{45}{0.18} \end{pmatrix} = \begin{pmatrix} -\frac{1000}{7} \\ 0 \end{pmatrix}$$

Найдём значение теста:

$$\begin{pmatrix} -\frac{1000}{7} & 0 \end{pmatrix} \cdot \frac{3}{250 \cdot 1500} \begin{pmatrix} 175 & -70 \\ -70 & 88 \end{pmatrix} \cdot \begin{pmatrix} -\frac{1000}{7} \\ 0 \end{pmatrix} = \frac{200}{7} = 28.57$$

$$\chi_{\text{crit}} = 3.84 < 28.57 \implies \text{гипотеза опровергается}$$

с) Проверим гипотезу по W тесту: $W = (\hat{p}_{UR} - p_0)^T \widehat{\text{Var}}^{-1}(\hat{p}_{UR})(\hat{p}_{UR} - p_0)$

Из предыдущего пункта имеем:

$$I = n \begin{pmatrix} \frac{1}{p_1} + \frac{1}{p_3} & \frac{1}{p_3} \\ \frac{1}{p_3} & \frac{1}{p_2} + \frac{1}{p_3} \end{pmatrix}$$

Из пункта (а) имеем оценки: $\hat{p}_{UR} = \begin{pmatrix} 0.5 \\ 0.2 \end{pmatrix}$, подставим в информацию:

$$\widehat{Var}^{-1}(\hat{p}_{UR}) = \hat{I}_{UR} = 150 \begin{pmatrix} \frac{16}{3} & \frac{10}{3} \\ \frac{10}{3} & \frac{25}{3} \end{pmatrix}$$

$$W = 150 \left(\begin{pmatrix} 0.5 \\ 0.2 \end{pmatrix} - \begin{pmatrix} 0.4 \\ 0.6 \end{pmatrix} \right)^T \cdot \begin{pmatrix} \frac{16}{3} & \frac{10}{3} \\ \frac{10}{3} & \frac{25}{3} \end{pmatrix} \cdot \begin{pmatrix} 0.5 \\ 0.2 \end{pmatrix} - \begin{pmatrix} 0.4 \\ 0.6 \end{pmatrix} = 168$$

$$\chi_{crit} = 5.99 < 168 \implies \text{гипотеза опровергается}$$

d) Из пунктов (a) и (c) имеем:

$$\hat{p}_{ML} = \begin{pmatrix} 0.5 \\ 0.2 \end{pmatrix} \qquad \hat{I}_{UR} = 150 \begin{pmatrix} \frac{16}{3} & \frac{10}{3} \\ \frac{10}{3} & \frac{25}{3} \end{pmatrix}$$

$$\hat{I}_{UR}^{-1} = \widehat{Var}(\hat{p}_{UR}) = \begin{pmatrix} \widehat{Var}(\hat{p}_1) & \widehat{Cov}(\hat{p}_1, \hat{p}_2) \\ \widehat{Cov}(\hat{p}_1, \hat{p}_2) & \widehat{Var}(\hat{p}_2) \end{pmatrix} = \frac{1}{15000} \begin{pmatrix} 25 & -10 \\ -10 & 16 \end{pmatrix}$$

$$\widehat{Var}(\hat{p}_1) = \frac{25}{15000} \qquad \widehat{Var}(\hat{p}_2) = \frac{16}{15000} \qquad \widehat{Cov}(\hat{p}_1, \hat{p}_2) = -\frac{10}{15000}$$

Найдём дисперсию и оценку $p_1 - p_2$:

$$\widehat{Var}(\hat{p}_1 - \hat{p}_2) = \widehat{Var}(\hat{p}_1) - 2\widehat{Cov}(\hat{p}_1, \hat{p}_2) + \widehat{Var}(\hat{p}_2) = \frac{25}{15000} - 2 \cdot \left(-\frac{10}{15000} \right) + \frac{16}{15000} = \frac{61}{15000}$$

$$\widehat{p_1 - p_2} = \hat{p}_1 - \hat{p}_2 = 0.5 - 0.2 = 0.3$$

Получаем 95%-ый доверительный интервал:

$$\left[0.3 - 1.96\sqrt{\frac{61}{15000}}; 0.3 + 1.96\sqrt{\frac{61}{15000}} \right] = [0.175; 0.425]$$

Ответ:

a) $\hat{p}_1 = 0.5, \hat{p}_2 = 0.2$

b) $LR = 26.153$, гипотеза опровергается; $LM = 28.57$, гипотеза опровергается

c) $W = 168$, гипотеза опровергается

d) $[0.175; 0.425]$

Задача 4

$$y_i = \beta_1 e^{\beta_2 x_i} u_i, \quad u_i \sim \mathcal{N}(0, 1)$$

а) Покажем, что данная зависимость линейна по β_1 :

Зафиксируем все переменные, кроме β_1 и рассмотрим зависимость как функцию от β_1 : $f(\beta_1) = \beta_1 e^{\beta_2 x_i} u_i$

- $f(a + b) = (a + b) e^{\beta_2 x_i} u_i = a e^{\beta_2 x_i} u_i + b e^{\beta_2 x_i} u_i = f(a) + f(b)$
- $f(ka) = (ka) e^{\beta_2 x_i} u_i = k \beta_1 e^{\beta_2 x_i} u_i = k f(a)$

Покажем, что данная зависимость нелинейна по β_2 :

Зафиксируем все переменные, кроме β_2 и рассмотрим зависимость как функцию от β_2 : $g(\beta_2) = \beta_1 e^{\beta_2 x_i} u_i$

- $g(ka) = \beta_1 e^{k a x_i} u_i \neq k \beta_1 e^{a x_i} u_i = k g(a)$ при $k \neq 1, x_i, a \neq 0$

б) Рассмотрим $\ln y_i$:

$$\ln y_i = \ln \beta_1 + \beta_2 x_i + \ln u_i$$

Из того, что $\ln u_i \sim \mathcal{N}(0, 1)$, получаем: $\ln y_i \sim \mathcal{N}(\ln \beta_1 + \beta_2 x_i, 1)$. Рассмотрим её функцию распределения:

$$f(\ln y) = \frac{1}{(2\pi)^{n/2}} \exp \left(-\frac{1}{2} \sum_{i=1}^n (\ln y_i - \ln \beta_1 - \beta_2 x_i)^2 \right)$$

$$\ell(\ln y) = -\frac{n}{2} \ln 2\pi - \frac{1}{2} \sum_{i=1}^n (\ln y_i - \ln \beta_1 - \beta_2 x_i)^2$$

Найдём оценки β_1, β_2 ММП:

$$\ell'_{\beta_1} = \frac{1}{\beta_1} \sum_{i=1}^n (\ln y_i - \ln \beta_1 - \beta_2 x_i) \quad \ell'_{\beta_2} = \sum_{i=1}^n (\ln y_i x_i - x_i \ln \beta_1 - \beta_2 x_i^2)$$

$$\begin{cases} \sum_{i=1}^n (\ln y_i - \ln \hat{\beta}_1 - \hat{\beta}_2 x_i) = 0 \\ \sum_{i=1}^n (\ln y_i x_i - x_i \ln \hat{\beta}_1 - \hat{\beta}_2 x_i^2) = 0 \end{cases} \iff \begin{cases} \ln \hat{\beta}_1 = \overline{\ln y} - \hat{\beta}_2 \bar{x} \\ \sum_{i=1}^n x_i \ln y_i - \overline{\ln y} \sum_{i=1}^n x_i = \hat{\beta}_2 \left(-\bar{x} \sum_{i=1}^n x_i + \sum_{i=1}^n x_i^2 \right) \end{cases}$$

$$\Longleftrightarrow \begin{cases} \ln \hat{\beta}_1 = \overline{\ln y} - \frac{\bar{x} \sum_{i=1}^n x_i (\ln y_i - \overline{\ln y})}{\sum_{i=1}^n x_i (x_i - \bar{x})} \\ \hat{\beta}_2 = \frac{\sum_{i=1}^n x_i (\ln y_i - \overline{\ln y})}{\sum_{i=1}^n x_i (x_i - \bar{x})} \end{cases}$$

Проверим, являются ли найденные значения точкой максимума:

$$\ell''_{\beta_1 \beta_1} = -\frac{1}{\beta_1^2} \sum_{i=1}^n (\ln y_i - \ln \beta_1 - \beta_2 x_i + 1) \quad \ell''_{\beta_2 \beta_2} = -\sum_{i=1}^n x_i^2 \quad \ell''_{\beta_1 \beta_2} = -\frac{1}{\beta_1} \sum_{i=1}^n x_i$$

$$H(\hat{\beta}) = \begin{pmatrix} -\frac{n}{\hat{\beta}_1^2} & -\frac{1}{\hat{\beta}_1} \sum_{i=1}^n x_i \\ -\frac{1}{\hat{\beta}_1} \sum_{i=1}^n x_i & -\sum_{i=1}^n x_i^2 \end{pmatrix}$$

$-\frac{n}{\hat{\beta}_1^2} < 0$, покажем, что $\det H(\hat{\beta}) > 0$:

$$\det H(\hat{\beta}) = \frac{n}{\hat{\beta}_1^2} \sum_{i=1}^n x_i^2 - \frac{1}{\hat{\beta}_1^2} \left(\sum_{i=1}^n x_i \right)^2$$

Из неравенства КБШ:

$$\left(\sum_{i=1}^n x_i \right)^2 < \left(\sum_{i=1}^n 1 \right) \cdot \left(\sum_{i=1}^n x_i^2 \right) = n \sum_{i=1}^n x_i^2$$

Таким образом, матрица H отрицательно определена, из чего следует, что $\hat{\beta}$ - точка максимума.

Ответ:

а) Зависимость линейна по β_1 , нелинейна по β_2

б)

$$\hat{\beta}_1 = \exp \left(\overline{\ln y} - \frac{\bar{x} \sum_{i=1}^n x_i (\ln y_i - \overline{\ln y})}{\sum_{i=1}^n x_i (x_i - \bar{x})} \right) \quad \hat{\beta}_2 = \frac{\sum_{i=1}^n x_i (\ln y_i - \overline{\ln y})}{\sum_{i=1}^n x_i (x_i - \bar{x})}$$